


CONHECIMENTO E RACIOCÍNIO

6 – Algoritmos de otimização

Regressão Linear

Mínimos quadrados

Gradiente descendente



Inteligência Artificial

**BASEADA EM
CONHECIMENTO
(Knowledge Based Agents)**


**APRENDIZAGEM
DE MÁQUINA
(Machine Learning)**

Inteligência Artificial



Aprendizagem de máquina

(Machine Learning)




Aprendizagem Supervisionada

- **Modelos de aprendizagem supervisionada**
 - **Modelos para resolver problemas de previsão:**
 - Usa valores numéricos contínuos
 - Previsão da evolução de ações
 - Previsão de preços da venda de imobiliário
 - ...
 - **Modelos para resolver problemas de classificação:**
 - Usa valores numéricos ou categóricos
 - Precisa de um “label” (target)
 - Identificação binária: por exemplo, Fraude - Sim/Não
 - Classificação em mais categorias: A, B, C.
 - ...

Aprendizagem Supervisionada


PREVISÃO

Modelos de Regressão



CLASSIFICAÇÃO

Redes Neuronais



Aprendizagem Supervisionada

Datasets

Classificação

Idade	Sexo	T. Arterial	Colesterol	Medicamento
23	F	ALTA	ALTO	A
47	M	BAIXA	ALTO	C
47	M	BAIXA	ALTO	C
28	F	NORMAL	ALTO	B
61	F	BAIXA	ALTO	A
22	F	NORMAL	ALTO	B
49	F	NORMAL	ALTO	A
41	M	BAIXA	ALTO	C
60	M	NORMAL	ALTO	A
43	M	BAIXA	NORMAL	A
47	F	BAIXA	ALTO	C
34	F	ALTA	NORMAL	A
43	M	BAIXA	ALTO	A
74	F	BAIXA	ALTO	A

FEATURES / ATRIBUTOS

CLASSES / LABELS

Previsão

Motor	Emissão CO2
2	196
2.4	221
1.5	136
3.5	255
3.5	244
3.5	230
3.7	232
3.7	255
3.7	267
2.4	212
2.4	225
3.5	239
5.9	359
5.9	359
4.7	338

VARIÁVEL
INDEPENDENTE

VARIÁVEL
DEPENDENTE

Aprendizagem Supervisionada

Metodologia

- **Preparar o dataset**
- **Dividir o dataset** em duas partes
 - Uma parte (maior) é usada para treinar o modelo
 - Outra parte (menor) é usada para testar o modelo
- Técnicas de divisão do dataset
 - Train/test split
 - Cross Validation
- **Avaliar o desempenho**
 - Na fase de treino
 - Na fase de teste/validação
 - Usar métricas de desempenho: erro, *accuracy*, ...

Aprendizagem Supervisionada

Metodologia - exemplo

Dataset de treino (80%)

Dataset de teste (20%)

Motor	Emissão CO2
2	196
2.4	221
1.5	136
3.5	255
3.5	244
3.5	230
3.7	232
3.7	255
3.7	267
2.4	212
2.4	225
3.5	239
5.9	359
5.9	359
4.7	338
4.7	354
4.7	338
4.7	354

Motor	Emissão CO2
2	196
1,5	136
3,5	255
3,5	244
3,5	230
3,7	232
3,7	255
2,4	225
3,5	239
5,9	359
5,9	359
4,7	338
4,7	354
4,7	338
4,7	354

Train/Test Split




Motor	Emissão CO2
2,4	221
2,4	212
3,7	267

Aprendizagem Supervisionada

Metodologia - exemplo

Motor	Emissão CO2
2	196
1,5	136
3,5	255
3,5	244
3,5	230
3,7	232
3,7	255
2,4	225
3,5	239
5,9	359
5,9	359
4,7	338
4,7	354
4,7	338
4,7	354



Aprendizagem Supervisionada

Metodologia - exemplo

Dataset de teste

Motor	Emissão CO2
2,4	221
2,4	212
3,7	267



Resultado obtido

Previsão CO2
198,5
198,5
266,0

Resultado esperado

Motor	Emissão CO2
2,4	221
2,4	212
3,7	267



Avaliação

Erro	Erro ²
-22,49	505,71
-13,49	181,93
-1,04	1,09

$$Y = 51,88 * X + 74$$

MÉTRICAS DE AVALIAÇÃO

Métrica	Valor
SSE (Sum of Squared Error)	688,73
MAE (Mean Absolute Error)	12,34
MSE (Mean of Squared Error)	229,58
RMSE (Root of MSE)	15,15
R2 (Coeficiente de determinação)	0,6

APRENDIZAGEM SUPERVISIONADA

MODELOS DE REGRESSÃO

Modelos de Regressão

- Método matemático utilizado para descrever relações entre variáveis
 - Regressão linear simples
 - Regressão linear múltipla
 - Regressão não linear

Modelos de Regressão

- Regressão linear simples:
 - Descreve uma relação entre **duas variáveis**
 - X é a variável independente (constante)
 - Y é a variável dependente (o que se pretende estimar/prever)
 - O modelo é descrito pela equação de **uma reta**.
- Regressão linear múltipla
 - Extensão do modelo de regressão linear simples
 - Descreve uma relação entre **várias variáveis** independentes X_i e uma variável dependente Y
 - O objetivo será o de construir um modelo que se ajuste melhor aos dados do que o modelo de regressão linear simples.
 - O modelo é descrito por **um plano**
- Regressão não linear
 - Usada para dados onde não existem relações lineares, mas polinomiais ou exponenciais, por exemplo.

Modelos de Regressão


Regressão linear simples

- Esta aula dará uma explicação do método de **regressão linear simples** para introdução de vários conceitos importantes em modelos de aprendizagem supervisionada:
 - Dataset (valores contínuos)
 - O que é um modelo?
 - Treino do modelo
 - Teste do modelo
 - Métricas de avaliação do modelo

Regressão linear simples

DATASET


Motor	Emissão CO2
2	196
2.4	221
1.5	136
3.5	255
3.5	244
3.5	230
3.7	232
3.7	255
3.7	267
2.4	212
2.4	225
3.5	239
5.9	359
5.9	359
4.7	338
4.7	354
4.7	338
4.7	354



COEFICIENTE DE PEARSON: 0.94

Regressão: coeficiente de Pearson


- Mostra a correlação dos dados
- Varia entre $[-1, 1]$
 - Valor de 1: correlação positiva
 - Valor de -1: correlação negativa
 - Valor de 0: sem correlação
- **Correlação não é causalidade!!!**



Regressão: **Correlação não é causalidade!!!**

- Spurious Correlations


<https://www.tylervigen.com/spurious-correlations>




tylervigen.com

Regressão linear simples

Motor	Emissão CO2
2	196
2.4	221
1.5	136
3.5	255
3.5	244
3.5	230
3.7	232
3.7	255
3.7	267
2.4	212
2.4	225
3.5	239
5.9	359
5.9	359
4.7	338
4.7	354
4.7	338
4.7	354



Regressão linear simples: resíduos



Resíduos = Erros

Diferença entre os valores observados e os valores estimados pela reta encontrada.

Regressão linear simples

Motor	Emissão CO2
2	196
2.4	221
1.5	136
3.5	255
3.5	244
3.5	230
3.7	232
3.7	255
3.7	267
2.4	212
2.4	225
3.5	239
5.9	359
5.9	359
4.7	338
4.7	354
4.7	338
4.7	354

No método de regressão simples o modelo consiste numa **reta que melhor se ajusta aos dados do dataset**



REGRESSÃO LINEAR

$$Y = Ax + B$$

$$Y = 54.14x + 82.4$$

OBJETIVO DO ALGORITMO: encontrar os valores dos coeficientes **A** e **B**


Regressão linear simples:

a equação da reta

$$Y = A.X + B$$


A é o coeficiente angular – declive

B é o coeficiente linear – ponto de interseção da reta em Y (quando $X = 0$)




Regressão linear simples: resíduos

- **Resíduos:** erros entre os valores observados e os valores estimados pela reta encontrada.



Regressão linear simples: previsão



3,5	239
5,9	359
5,9	359
4,7	338
4,7	354
4,7	338
4,7	354
5	???

→ 333,19

REGRESSÃO LINEAR
 $Y = 50.14 X + 82.48$

Regressão linear simples

- Como encontrar a reta que melhor se ajusta aos dados?
 - Método dos mínimos quadrados (MMQ):
 - Método não iterativo que ajusta um modelo de forma a minimizar a soma dos quadrados **das diferenças entre os valores observados e os valores previstos (resíduos)**.
 - Método do gradiente descendente
 - Método numérico iterativo que encontra um mínimo (local) de uma função, onde em cada iteração se toma a direção (negativa) do gradiente, que corresponde à direção de declive máximo.

Regressão linear simples

Método dos mínimos quadrados (MMQ)


Regressão linear simples

Método dos mínimos quadrados (MMQ)

- Método não iterativo que ajusta um modelo de forma a minimizar a soma dos quadrados **das diferenças entre os valores observados e os valores previstos (resíduos)**.

$$erro_i = y_i - \hat{y}_i$$

Observado Previsto



Regressão linear simples

Método dos mínimos quadrados (MMQ)

Calcular os resíduos para todos os valores do dataset

Motor	Emissão CO2	Previsão	Resíduo (Erro)	Quadrado do erro
2	196	183	13,2	175,3
2,4	221	203	18,2	330,6
1,5	136	158	-21,7	470,4
3,5	255	258	-3,0	8,8
3,5	244	258	-14,0	195,3
3,5	230	258	-28,0	782,6
3,7	232	268	-36,0	1296,2
3,7	255	268	-13,0	169,1
3,7	267	268	-1,0	1,0
2,4	212	203	9,2	84,3
2,4	225	203	22,2	492,1
3,5	239	258	-19,0	360,0
5,9	359	378	-19,3	373,2
5,9	359	378	-19,3	373,2
4,7	338	318	19,9	394,2
4,7	354	318	35,9	1285,5
4,7	338	318	19,9	394,2
4,7	354	318	35,9	1285,5
Total				8471,5


SSE: Sum of Squared Errors

Soma dos quadrados dos erros

Regressão linear simples

Método dos mínimos quadrados (MMQ)

- Objetivo: encontrar os parâmetros **a** e **b** da equação da reta que melhor se ajusta aos dados
- Como? Minimizar a soma dos quadrados das diferenças entre os valores observados e os valores previstos (**distância entre dois pontos**).



Objetivo:
minimizar esta
função



SOMATÓRIO DOS ERROS AO QUADRADO

$$SSE = \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

SSE

$$SSE = \sum_{i=1}^n (y_i - (ax_i + b))^2$$

Regressão linear simples

Método dos mínimos quadrados (MMQ)

- COMO MINIMIZAR A FUNÇÃO?
 - Usar as derivadas parciais da função: derivar em função a ***a*** e em função a ***b***

SUM OF SQUARED ERRORS

$$\sum_{i=1}^n (y_i - ax_i - b)^2$$

- Para encontrar os parâmetros ***a*** e ***b*** da equação da reta: **$y = ax + b$**

RESOLVER O SISTEMA DE EQUAÇÕES

$$\begin{cases} a \sum_{i=1}^n x_i^2 + b \sum_{i=1}^n x_i = \sum_{i=1}^n x_i \cdot y_i \\ a \sum_{i=1}^n x_i + b \cdot n = \sum_{i=1}^n y_i \end{cases}$$

Como obter este sistema de equações usando as derivadas parciais?

>> Regra da cadeia, Regra da potência.

<https://www.youtube.com/watch?v=WuPKvp-X7Y>

Regressão linear simples

Método dos mínimos quadrados (MMQ)

x_i	y_i	x_i^2	$x_i \cdot y_i$	
1	7	1	7	
3	10	9	30	
4	15	16	60	
8	32	26	97	SOMATÓRIOS

RESOLVER O SISTEMA DE EQUAÇÕES

$$\begin{cases} a \sum_{i=1}^n x_i^2 + b \sum_{i=1}^n x_i = \sum_{i=1}^n x_i \cdot y_i \\ a \sum_{i=1}^n x_i + b \cdot n = \sum_{i=1}^n y_i \end{cases}$$

$$\begin{cases} 26a + 8b = 97 \\ 8a + 3b = 32 \end{cases} \quad \begin{cases} a = 2,5 \\ 8a + 3b = 32 \end{cases} \quad \begin{cases} a = 2.5 \\ b = 4 \end{cases}$$

Reta: $y = ax + b$

$$**y = 2.5x + 4**$$

Regressão Linear

Métricas de avaliação

- SSE
$$SSE = \sum_{i=1}^n (y_i - \hat{y}_i)^2$$
- MAE
$$MAE = \frac{\sum_{i=1}^n |y_i - \hat{y}_i|}{n}$$
- MSE
$$MSE = \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{n}$$
- RMSE
$$RMSE = \sqrt{\frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{n}}$$

Regressão Linear

Coeficiente de determinação R^2

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

- Consiste no valor do **coeficiente de Pearson** ao quadrado
- R^2 : varia entre 0 e 1
- Representa a percentagem da variação nos dados que é explicada pelo modelo.
- Se o R^2 for próximo de 1, isso significa que o modelo se ajusta bem aos dados
- Se o R^2 for próximo de 0, isso significa que o modelo não se ajusta bem aos dados

Regressão linear – aprendizagem supervisionada

Exemplo

Considere o seguinte dataset onde se registaram os tempos de estudo de 10 estudantes e as notas obtidas no teste. Analise o dataset e responda às seguintes questões:

Tempo estudo (h)	Nota (0-10)
1	2,5
4	3,7
6	3,9
8	4,2
10	4,6
12	5,5
15	6,3
17	7,8
20	9,7
22	10

Assuma que a equação da reta dada por estes dados é:

$$y = 0.36x + 1.66$$

- Os dados da tabela têm alguma correlação usando o modelo dado? Justifique.
- Proponha uma divisão split 50%/50% para treinar e testar o modelo
- Qual a reta que melhor aproxima os **dados de treino (MMQ)**?
- Avalie o modelo usando os **dados de teste**:
 - Calcule erro absoluto médio (MAE)
 - Calcule erro quadrático médio (MSE)
- Usando o modelo treinado em b) qual a nota prevista no caso do aluno ter um tempo de estudo de 8 horas?

Regressão linear simples

Exemplo – 1a

- Coeficiente de Pearson avalia a correlação dos dados
- CP = **R**

$$y = 0.36x + 1.66$$

X: Tempo estudo (h)	Y: Nota real	Y': Nota estimada	Resíduos (Erros)	quadrado do erro	$(y_i - \bar{y})^2$	$(y_i - y'_i)^2$
1	2,5	2,02	-0,48	0,23	11,02	0,23
4	3,7	3,1	-0,6	0,36	4,49	0,36
6	3,9	3,82	-0,08	0,01	3,69	0,01
8	4,2	4,54	0,34	0,12	2,62	0,12
10	4,6	5,26	0,66	0,44	1,49	0,44
12	5,5	5,98	0,48	0,23	0,10	0,23
15	6,3	7,06	0,76	0,58	0,23	0,58
17	7,8	7,78	-0,02	0,00	3,92	0,00
20	9,7	8,86	-0,84	0,71	15,05	0,71
22	10	9,58	-0,42	0,18	17,47	0,18
Média(y)	5,82			$\sum \rightarrow$	60,10	2,84

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$


$$R^2 = 1 - (2,84/60,1) = 0.953$$

$$CP = \sqrt{R^2} = 0.976$$

Os dados possuem uma correlação próxima de 1, logo estão fortemente correlacionados

Regressão linear – aprendizagem supervisionada

Exemplo – 1a



Tempo estudo (h)	Nota (0-10)
1	2,5
4	3,7
6	3,9
8	4,2
10	4,6
12	5,5
15	6,3
17	7,8
20	9,7
22	10

Regressão linear – aprendizagem supervisionada

Exemplo 1 b)

b) Proponha uma divisão split 50%/50% para treinar e testar o modelo: dividir aleatoriamente os dados, por exemplo:

Tempo estudo (h)	Nota (0-10)
1	2,5
4	3,7
6	3,9
8	4,2
10	4,6
12	5,5
15	6,3
17	7,8
20	9,7
22	10

Split 50%/50%



CONJUNTO DE TREINO

Tempo estudo (h)	Nota (0-10)
1	2,5
6	3,9
8	4,2
12	5,5
22	10

CONJUNTO DE TESTE

Tempo estudo (h)	Nota (0-10)
4	3,7
10	4,6
15	6,3
17	7,8
20	9,7

Regressão linear – aprendizagem supervisionada

Exercício 1 c)

c) Qual a reta que melhor aproxima os **dados de treino**?

- Encontrar a reta $y = ax + b$ para o conjunto de treino
- Método dos mínimos quadrados

RESOLVER O SISTEMA DE EQUAÇÕES

$$\begin{cases} a \sum_{i=1}^n x_i^2 + b \sum_{i=1}^n x_i = \sum_{i=1}^n x_i \cdot y_i \\ a \sum_{i=1}^n x_i + b \cdot n = \sum_{i=1}^n y_i \end{cases}$$

CONJUNTO DE TREINO

Tempo estudo (h)	Nota (0-10)
1	2,5
6	3,9
8	4,2
12	5,5
22	10

X: Tempo estudo (h)	Y: Nota (0-10)	X_i^2	$X_i \cdot Y_i$
1	2,5	1	2,5
6	3,9	36	23,4
8	4,2	64	33,6
12	5,5	144	66
22	10	484	220
49	26,1	729	345,5

$$\begin{cases} 729a + 49b = 345,5 \\ 49a + 5b = 26,1 \end{cases}$$

$$\begin{cases} a = 0,36 \\ 49a + 5b = 26,1 \end{cases}$$

$$\begin{cases} a = 0,36 \\ b = 1,69 \end{cases}$$

Qual a reta que melhor aproxima os dados de treino?

Resposta: **$y = ax + b \gg y = 0,36x + 1,69$**

Regressão linear – aprendizagem supervisionada

Exercício 1 d)

d) Avalie o modelo usando os **dados de teste**:

- Calcule erro absoluto médio (MAE)
- Calcule erro quadrático médio (MSE)

O nosso modelo treinado

$$y = ax + b \gg y = 0,36x + 1,69$$

vai ser aplicado ao conjunto de teste

CONJUNTO DE TESTE

Tempo estudo (h)	Nota (0-10)
4	3,7
10	4,6
15	6,3
17	7,8
20	9,7

X: Tempo estudo (h)	Y: Nota (0-10)	Y estimado	Resíduos (Erro)	Erro ^2	Erro
4	3,7	3,13	-0,57	0,3249	0,57
10	4,6	5,29	0,69	0,4761	0,69
15	6,3	7,09	0,79	0,6241	0,79
17	7,8	7,81	0,01	0,0001	0,01
20	9,7	8,89	-0,81	0,6561	0,81
				2,0813	2,87

$$MSE = \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{n} = \frac{2,0813}{5} = 0,416$$

$$MAE = \frac{\sum_{i=1}^n |y_i - \hat{y}_i|}{n} = \frac{2,87}{5} = 0,574$$

Regressão linear – aprendizagem supervisionada

Exercício 1 e)

e) Usando o modelo treinado em b) qual a nota prevista no caso do aluno ter um tempo de estudo de 8 horas?

O nosso modelo treinado

$$y = ax + b \gg y = 0,36x + 1,69$$

vai ser aplicado a $x = 8$



$$y = 4,57$$

A nota prevista será de 4,57



Tempo estudo (h)	Nota (0-10)
1	2,5
4	3,7
6	3,9
8	4,2
10	4,6
12	5,5
15	6,3
17	7,8
20	9,7
22	10

Outros modelos de regressão

- Regressão linear simples e múltipla



- Regressão não linear: polinomial, exponencial, ...



Gradiente descendente

Regressão linear simples

Gradiente descendente

- Método do gradiente – também designado por método do declive máximo:
 - Método numérico usado para otimização usado em algoritmos de aprendizagem supervisionada
 - Otimizar os parâmetros da reta de regressão linear
 - Otimizar os pesos de uma rede neuronal
 - ... Consegue otimizar os parâmetros de qualquer algoritmo que possua uma função de erro que se pretende minimizar
- Algoritmo iterativo que permite encontrar o mínimo local de uma função (***loss function***)
 - Cada iteração dirige o algoritmo para uma direção negativa que corresponde ao declive máximo

Regressão linear simples


Gradiente descendente

- Algoritmo de otimização usado em muitos modelos de aprendizagem supervisionada
 - **Hoje:** usar o algoritmo do gradiente descendente para encontrar os valores de **a** e **b** da reta da regressão linear simples
 - **Em breve:** usar o algoritmo do gradiente descendente para otimizar os pesos de uma rede neuronal

Regressão linear simples

Gradiente descendente


Ajustar parâmetros aleatoriamente: moroso e pouco eficiente



Regressão linear simples

Gradiente descendente


Gradiente descendente: ajustar parâmetros através da minimização do erro



Regressão linear simples

Gradiente descendente

Motor	Emissão CO2
2	196
2.4	221
1.5	136
3.5	255
3.5	244
3.5	230
3.7	232
3.7	255
3.7	267
2.4	212
2.4	225
3.5	239
5.9	359
5.9	359
4.7	338
4.7	354
4.7	338
4.7	354



Gradiente descendente:

Calcular iterativamente os valores de **a** e de **b** que minimizam a soma dos quadrados dos erros (SSE = *Loss Function*)


Regressão linear simples

Gradiente descendente

$$SSE = \sum_{i=1}^n (y_i - \hat{y}_i)^2$$


X	Y
1	3
2	4
3	5

X	Y'
1	2.5
2	4.5
3	6.5



Valores aleatórios, por exemplo: $a = 2$, $b = 0.50$



$$SSE = (3 - 2.5)^2 + (4 - 4.5)^2 + (5 - 6.5)^2 = 2.75$$



Ao fim de 700 iterações:
 $a = 1$ $b = 2$ $sse = 0.00$

Regressão linear simples

Gradiente descendente



- Nas primeiras iterações há ajustes maiores (derivadas parciais maiores)
- Nas últimas iterações o Gradiente Descendente faz ajustes pequenos (derivadas parciais diminuem em cada iteração)
 - Iterar até encontrar o valor ótimo (erro próximo de zero ou não conseguir melhorar o erro)


Regressão linear simples

Gradiente descendente

- Começar com uma reta aleatória
 - Escolher **a** e **b** aleatórios
- Calcular o custo (erro)
 - Use a soma do quadrado dos erros (SSE)
- Iterativamente diminuir o valor do **custo** (minimizar SSE):
 - $a = a - LR * \frac{\partial \text{custo}}{\partial a}$
 - $b = b - LR * \frac{\partial \text{custo}}{\partial b}$
- LR: *Learning Rate, ajusta a velocidade do algoritmo (saltos em cada iteração)*
Normalmente usam-se valores típicos 0.1, 0.01, 0.001

Regressão linear simples


Gradiente descendente



Valores aleatórios, por exemplo: $a = 5$, $b = 7$

Custo = SSE

$$SSE = \sum_{i=1}^n (y_i - \hat{y}_i)^2$$



Diminuir o custo, ajustar o valor de a e b

$$a = a - LR * \frac{\partial \text{custo}}{\partial a}$$

$$b = b - LR * \frac{\partial \text{custo}}{\partial b}$$

Regressão linear simples

Gradiente descendente

- Em cada iteração minimizar a função de custo SSE:

$$SSE = \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

$$SSE = \sum_{i=1}^n (y_i - (ax_i + b))^2$$



Calcular as derivadas parciais desta função!

Regressão linear simples

Gradiente descendente

Substituindo custo por SSE

$$\begin{aligned} a &= a - LR * \frac{\partial \text{custo}}{\partial a} \\ b &= b - LR * \frac{\partial \text{custo}}{\partial b} \end{aligned}$$



$$a = a - LR * \frac{\partial \sum_{i=1}^n (y_i - \hat{y}_i)^2}{\partial a}$$

$$b = b - LR * \frac{\partial \sum_{i=1}^n (y_i - \hat{y}_i)^2}{\partial b}$$

Mas... ($\hat{y}_i = ax + b$), logo
expandindo a fórmula temos:

$$a = a - LR * \frac{\partial \sum_{i=1}^n (y_i - (ax_i + b))^2}{\partial a}$$

$$b = b - LR * \frac{\partial \sum_{i=1}^n (y_i - (ax_i + b))^2}{\partial b}$$

Regressão linear simples

Gradiente descendente

Próximo passo: calcular as derivadas parciais:

Regra da cadeia

Regra da potência

$$a = a - LR * \frac{\partial \sum_{i=1}^n (y_i - (ax_i + b))^2}{\partial a}$$



$$b = b - LR * \frac{\partial \sum_{i=1}^n (y_i - (ax_i + b))^2}{\partial b}$$

$$a = a - LR * 2 \sum_{i=1}^n (ax_i + b - y_i) \cdot x_i$$

$$b = b - LR * 2 \sum_{i=1}^n (ax_i + b - y_i)$$

Regressão linear simples

Método do Gradiente Descendente - exemplo

x_i	y_i
1	7
3	10
4	15


LR = 0,01 (coeficiente de aprendizagem)

$$a = a - LR * 2 \sum_{i=1}^n (ax_i + b - y_i) \cdot x_i$$

$$b = b - LR * 2 \sum_{i=1}^n (ax_i + b - y_i)$$

Iteração 1

$a = 8$ e $b = 12$ (aleatórios)



SSE = 1686

Ajustar a e b

x_i	y_i	$(ax_i + b - y_i) \cdot x_i$	$ax_i + b - y_i$
1	7	13	13
3	10	78	26
4	15	116	29
$2 * \sum$		414	136

$$a = 8 - 0,01 * 414 = 3,86$$

$$B = 12 - 0,01 * 136 = 10,64$$

SSE = 328,34

Regressão linear simples

Método do Gradiente Descendente - exemplo

x_i	y_i
1	7
3	10
4	15

LR = 0,01 (coeficiente de aprendizagem)

$$a = a - LR * 2 \sum_{i=1}^n (ax_i + b - y_i) \cdot x_i$$

$$b = b - LR * 2 \sum_{i=1}^n (ax_i + b - y_i)$$

Iteração 2

$a = 3,86$ e $b = 10,64$

SSE = 328,345

Ajustar a e b

x_i	y_i	$(ax_i + b - y_i) \cdot x_i$	$ax_i + b - y_i$
1	7	7,5	7,5
3	10	36,66	12,22
4	15	44,32	11,08
$2 * \sum$		176,96	61,6

$$a = 3,86 - 0,01 * 176,96 = 2,09$$

$$b = 10,64 - 0,01 * 61,6 = 10,024$$

SSE = 77,25

Regressão linear simples

Método do Gradiente Descendente - exemplo

x_i	y_i
1	7
3	10
4	15

LR = 0,01 (coeficiente de aprendizagem)

$$a = a - LR * 2 \sum_{i=1}^n (ax_i + b - y_i) \cdot x_i$$

$$b = b - LR * 2 \sum_{i=1}^n (ax_i + b - y_i)$$

Iteração 3

$a = 2,09$ e $b = 10,024$

SSE = 77,25

Ajustar a e b

x_i	y_i	$(ax_i + b - y_i) \cdot x_i$	$ax_i + b - y_i$
1	7	5,11	5,11
3	10	18,89	6,30
4	15	13,54	3,39
$2 * \sum$		75,08	29,59

$a = 2,09 - 0,01 * 75,08 = 1,340$
 $b = 10,024 - 0,01 * 29,59 = 9,728$

SSE = 30,59

Regressão linear simples

Método do Gradiente Descendente - exemplo

a = 8.00 b= 12.00 sse = 1686.00

ITERACAO 1

a = 3.86 b= 10.64 sse = 328.34

ITERACAO 2

a = 2.09 b= 10.02 sse = 77.25

ITERACAO 3

a = 1.34 b= 9.73 sse = 30.59

ITERACAO 4

a = 1.03 b= 9.57 sse = 21.71

ITERACAO 5

a = 0.90 b= 9.47 sse = 19.81

ITERACAO 6

a = 0.86 b= 9.40 sse = 19.21

ITERACAO 7

a = 0.85 b= 9.34 sse = 18.85

ITERACAO 8

a = 0.85 b= 9.28 sse = 18.54

ITERACAO 9

a = 0.86 b= 9.23 sse = 18.24

ITERACAO 10

a = 0.88 b= 9.18 sse = 17.95

ITERACAO 91

a = 1.77 b= 6.33 sse = 6.42

ITERACAO 92

a = 1.78 b= 6.30 sse = 6.36

ITERACAO 93

a = 1.78 b= 6.28 sse = 6.31

ITERACAO 94

a = 1.79 b= 6.26 sse = 6.25

ITERACAO 95

a = 1.80 b= 6.24 sse = 6.20

ITERACAO 96

a = 1.81 b= 6.22 sse = 6.15

....

ITERACAO 714 ... 1000

a = 2.50 b= 4.00 sse = 3.50

REGRESSÃO LINEAR SIMPLES

EXERCÍCIOS

Regressão linear simples

Exercício 1 - método dos mínimos quadrados


Considere o seguinte dataset com preços de casas baseados nas respectivas topologias

Nº quartos x_i	Preço (* 1000 eur) y_i
1	15
2	35
3	40

- a) Qual a reta que melhor aproxima os dados?
Use o método dos mínimos quadrados
- b) Calcule erro quadrático médio (MSE)
- c) Calcule o valor do coeficiente de determinação R^2
- d) Qual o preço previsto para uma casa com uma topologia de 5 quartos?

Regressão linear simples

Exercício 1 a)



Regressão linear simples

Exercício 1 a)

- Método dos mínimos quadrados

Nº quartos	Preço (* 1k eur)	x_i^2	$x_i \cdot y_i$
1	15	1	15
2	35	4	70
3	40	9	120
6	90	14	205

RESOLVER O SISTEMA DE EQUAÇÕES

$$\begin{cases} a \sum_{i=1}^n x_i^2 + b \sum_{i=1}^n x_i = \sum_{i=1}^n x_i \cdot y_i \\ a \sum_{i=1}^n x_i + b \cdot n = \sum_{i=1}^n y_i \end{cases}$$

$$\begin{cases} 14a + 6b = 205 \\ 6a + 3b = 90 \end{cases} \quad \begin{cases} a = 12,5 \\ 6a + 3b = 90 \end{cases}$$

$$\begin{cases} a = 12,5 \\ b = 5 \end{cases}$$

Qual a reta que melhor aproxima os dados?

Resposta: $y = ax + b \gg y = 12,5x + 5$

Regressão linear simples

Exercício 1 b)

- Erro quadrático médio (MSE)

Nº quartos	Preço (* 1k eur)	Preço estimado	Resíduos	Quadrado do erro
1	15	17,5	2,5	6,25
2	35	30	-5	25
3	40	42.4	2.5	6,25

$$MSE = \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{n} = \frac{37,5}{3} = 12,5$$

Regressão linear simples

Exercício 1 c)

- Coeficiente de determinação R^2

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

$$SSE = \sum_{i=1}^n (y_i - \hat{y}_i)^2 = 37,5$$

$$SST = \sum_{i=1}^n (y_i - \bar{y})^2 = 350$$

Nº quartos	Preço real y_i	Preço estimado $\hat{y}_i$	Resíduos (erros)	Quadrado do erro	$(y_i - \bar{y})^2$
1	15	17,5	2,5	6,25	225
2	35	30	-5	25	25
3	40	42,4	2,5	6,25	100
				37,5	350

$$\bar{y} = \frac{15 + 35 + 40}{3} = 30$$

$$R^2 = 0,8929$$

Regressão linear simples

Exercício 1 d)

- Previsão de preço para um T5?

Qual a reta que melhor aproxima os dados?

Resposta: $y = ax + b \gg y = 12,5x + 5$

Logo, para $x = 5$

$y = 67,5$

Nº quartos	Preço (* 10k eur)
1	15
2	35
3	40
5	67,5

Regressão linear simples

Exercício 2 - gradiente descendente

Considere o seguinte dataset com preços de casas baseados nas respectivas topologias

Nº quartos x_i	Preço (* 1000 eur) y_i
1	15
2	35
3	40

Qual a reta que melhor aproxima os dados?

- Inicie o algoritmo com os valores aleatórios $a = 8$ e $b = 12$
- Use coeficiente de aprendizagem = 0,01
- Execute três iterações do método do **gradiente descendente**

Regressão linear simples

Exercício 2 - resolução

X	Y
1	15
2	35
3	40

LR = 0,01 (coeficiente de aprendizagem)

$$a = a - LR * 2 \sum_{i=1}^n (ax_i + b - y_i) \cdot x_i$$

$$b = b - LR * 2 \sum_{i=1}^n (ax_i + b - y_i)$$

Iteração 1

a = 8 e b = 12 (aleatórios)

y = ax + b

X _i	y' _i
1	20
2	28
3	36

$$y'_1 = 8 \cdot 1 + 12 = 20$$

$$y'_2 = 8 \cdot 2 + 12 = 28$$

$$y'_3 = 8 \cdot 3 + 12 = 36$$

Ajustar a e b

x _i	y _i	(ax _i + b - y _i) · x _i	ax _i + b - y _i
1	15	(8*1 + 12 - 15)*1 = 5	8*1 + 12 - 15 = 5
2	35	(8*2 + 12 - 35)*2 = -14	8*2 + 12 - 35 = -7
3	40	(8*3 + 12 - 40)*3 = -12	8*3 + 12 - 40 = -4
2 * Σ		-42	-12

$$\begin{aligned} SSE &= (15-20)^2 + (35-28)^2 + (40-36)^2 = \\ &= 25 + 49 + 16 = 90 \end{aligned}$$

$$a = 8 - 0,01 * (-42) = 8,42$$

$$B = 12 - 0,01 * (-12) = 12,12$$

$$SSE = 74,04$$

Regressão linear simples

Exercício 2 - resolução

X	Y
1	15
2	35
3	40

LR = 0,01 (coeficiente de aprendizagem)

$$a = a - LR * 2 \sum_{i=1}^n (ax_i + b - y_i) \cdot x_i$$

$$b = b - LR * 2 \sum_{i=1}^n (ax_i + b - y_i)$$

Iteração 2

a = 8,42 e b = 12,12

X _i	y' _i
1	20,54
2	28,96
3	37,38

SSE = 74,04

Ajustar a e b

x _i	y _i	(ax _i + b - y _i) · x _i	ax _i + b - y _i
1	15	5,54	5,54
2	35	-12,08	-6,04
3	40	-7,86	-2,62
2 * Σ.		-28,8	-6,24

$$a = 8,42 - 0,01 * (-28,8) = 8,71$$

$$B = 12,12 - 0,01 * (-6,24) = 12,18$$

SSE = 66,74

Regressão linear simples

Exercício 2 - resolução

X	Y
1	15
2	35
3	40

LR = 0,01 (coeficiente de aprendizagem)

$$a = a - LR * 2 \sum_{i=1}^n (ax_i + b - y_i) \cdot x_i$$

$$b = b - LR * 2 \sum_{i=1}^n (ax_i + b - y_i)$$

Iteração 2

a = 8,71 e b = 12,18

X _i	y' _i
1	20,89
2	29,60
3	38,31

SSE = 66,74

Ajustar a e b

x _i	y _i	(ax _i + b - y _i) · x _i	ax _i + b - y _i
1	15	5,89	5,89
2	35	-10,80	-5,40
3	40	-5,08	-1,69
2 * Σ		-19,99	-2,41

$$a = 8,42 - 0,01 * (-19,99) = 8,91$$

$$B = 12,12 - 0,01 * (-2,41) = 12,21$$

SSE = 63,31